LAPORAN
MATA KULIAH



Nama	: Muhammad Hafizh Wijdan
NIM	: 202431005
Kelas	: Pembelajaran Mesin H
Nama Dosen	: Rizqia Cahyaningtyas, ST, M.Kom.
No. Bangku	: 08
Nama Asisten	:

1. MUHAMMAD ICHWAN FAUZI
2. BENEDICT SAMUEL ARDY

LABORATORIUM COMPUTER NETWORK
INSTITUT TEKNOLOGI PLN
2026

DAFTAR ISI

BAB I 3
PENDAHULUAN 3
1.1 Rumusan Masalah 3
1.2 Tujuan Masalah 3
1.3 Manfaat Masalah 4
BAB II 5
LANDASAN TEORI 5
BAB III 9
PEMBAHASAN 9
BAB IV 26
PENUTUP 26
DAFTAR PUSTAKA 28

BAB I

PENDAHULUAN

1.1 Rumusan Masalah

Di era ledakan data (*big data*) saat ini, *Machine Learning* telah menjadi pilar utama dalam mentransformasi data mentah menjadi wawasan prediktif yang bernilai strategis di berbagai sektor kehidupan. Namun, data mentah yang diperoleh dari berbagai sumber (baik melalui API maupun *web scraping*) sering kali bersifat kotor, tidak lengkap, dan mengandung anomali. Oleh karena itu, diperlukan tahapan *Exploratory Data Analysis* (EDA) sebagai fase penyelidikan investigatif untuk memahami anatomi dataset, serta *Data Preprocessing* sebelum menerapkan algoritma pemodelan kuantitatif seperti Regresi Linear pada studi kasus riil (dataset *stroke* dan dataset probabilitas kebotakan).

Berdasarkan latar belakang praktikum yang telah dilakukan, maka rumusan masalah dalam laporan ini adalah sebagai berikut:

1. Bagaimana cara melakukan inspeksi awal untuk memahami struktur dataset yang meliputi dimensi, tipe data, dan statistik ringkasan melalui *Exploratory Data Analysis* (EDA)?
2. Bagaimana cara mendeteksi serta menangani permasalahan kualitas data seperti nilai kosong (*missing values*) dan pencilan (*outliers*) pada tahap *Data Preprocessing*?
3. Bagaimana cara merancang dan menginterpretasikan visualisasi data yang informatif (*countplot*, *boxplot*, *scatterplot*, *heatmap* korelasi, dan *pairplot*) untuk mengungkap pola serta korelasi antar-variabel?
4. Bagaimana prinsip matematis dan langkah implementasi kode bahasa pemrograman Python dalam membangun model Regresi Linear Sederhana serta Regresi Linear Berganda (termasuk tahapan *train-test split*)?
5. Bagaimana cara mengevaluasi kinerja model regresi dan menginterpretasikan metrik evaluasinya seperti Koefisien Regresi (*Slope*), *Intercept*, *Mean Squared Error* (MSE), dan *R-squared* (R^2 *Score*)?

1.2 Tujuan Masalah

Berdasarkan rumusan masalah di atas, adapun tujuan dan hasil yang telah diperoleh dari pelaksanaan praktikum ini adalah:

1. Mampu melakukan inspeksi awal struktur dataset, meliputi pemeriksaan dimensi baris dan kolom, identifikasi tipe data, serta perhitungan statistik ringkasan menggunakan pustaka Pandas dan NumPy.
2. Mampu mendeteksi dan mengatasi masalah kualitas data seperti nilai kosong (*missing values*) melalui teknik imputasi atau penghapusan, serta menangani pencilan (*outliers*) agar distribusi data menjadi lebih optimal.
3. Mampu merancang visualisasi data yang informatif menggunakan pustaka Matplotlib dan Seaborn (meliputi *countplot*, *boxplot*, *scatterplot*, *heatmap* korelasi, dan *pairplot*) guna melihat sebaran data serta kekuatan hubungan antar-fitur.
4. Memahami prinsip matematis dan berhasil mengimplementasikan kode pemrograman Regresi Linear Sederhana serta menginterpretasikan persamaan garis regresinya.
5. Mampu melakukan tahapan *data preprocessing*, pembagian data (*train-test split*), pelatihan model, hingga pengujian pada Regresi Linear Berganda menggunakan pustaka Scikit-Learn.

6. Mampu menghitung dan menginterpretasikan metrik evaluasi model prediktif yang dihasilkan, meliputi nilai Koefisien Regresi, *Intercept*, tingkat kesalahan *Mean Squared Error* (MSE), dan proporsi variansi pada *R-squared* (R^2 *Score*).

1.3 Manfaat Masalah

Adapun manfaat yang diperoleh setelah menyelesaikan rangkaian praktikum *end-to-end pipeline* sains data ini adalah sebagai berikut:

1. **Manfaat Teoritis (Akademis):** Memberikan pemahaman komprehensif mengenai alur kerja siklus hidup *Machine Learning* (*Machine Learning Life Cycle*), mulai dari tahap definisi masalah, pengumpulan data otomatis, eksplorasi dan pra-pemrosesan data, hingga konsep matematis di balik algoritma *supervised learning* Regresi Linear Sederhana dan Berganda.
2. **Manfaat Praktis (Teknis):** Meningkatkan keterampilan teknis mahasiswa dalam mengoperasikan bahasa pemrograman Python beserta ekosistem pustaka sains data mutakhir (*Pandas, NumPy, Matplotlib, Seaborn,* dan *Scikit-Learn*) untuk membersihkan data kotor dan membangun model prediksi yang akurat.
3. **Manfaat Aplikatif (Studi Kasus Riil):** Memberikan pengalaman langsung dalam memecahkan permasalahan prediksi di dunia nyata—khususnya dalam menganalisis faktor-faktor yang memengaruhi risiko kesehatan (dataset *stroke*) dan kondisi fisik/biologis (dataset probabilitas kebotakan)—sehingga dapat dijadikan landasan dalam pengambilan keputusan berbasis data (*data-driven decision making*).

BAB II

LANDASAN TEORI

1. Konsep Dasar Machine Learning & Workflow Data:

Machine learning adalah proses membuat komputer belajar dari data tanpa diberikan instruksi yang jelas." Ini berarti bahwa sistem Machine Learning mempelajari dari data dan membuat generalisasi sendiri tentang bagaimana mengatasi masalah, tanpa diberikan instruksi yang spesifik oleh pemrogram.

Perbedaan utama antara Machine Learning dan pemrograman konvensional adalah bahwa pemrograman konvensional memerlukan pemrogram untuk menentukan secara eksplisit bagaimana sistem harus bereaksi terhadap masukan, sementara Machine Learning memperbolehkan sistem mempelajari dan membuat generalisasi sendiri dari data." Ini berarti bahwa pemrogram harus menulis kode secara manual untuk setiap kemungkinan masukan dalam pemrograman konvensional, sementara sistem Machine Learning dapat mempelajari dan membuat generalisasi sendiri dari data yang diterimanya. Pemahaman terhadap suatu sistem harus dipahami dengan struktur sistem secara komprehensif. Bahwa hubungan suatu komponen sifatnya tidak harus linear namun juga bersifat circular dan saling mengunci[1]

A. Problem Definition. Tahap awal dalam alur kerja ini adalah mendefinisikan permasalahan yang akan diselesaikan secara spesifik, seperti menentukan jenis masalah (klasifikasi, regresi, clustering) dan menetapkan metrik evaluasinya [3]. Tahap ini sangat krusial karena kesalahan dalam mendefinisikan masalah akan berdampak pada seluruh proses selanjutnya, contohnya dalam menentukan prediksi pelanggan yang akan berhenti berlangganan [3].

B. Data Collection & Preparation. Pada tahap ini dilakukan pengumpulan dan persiapan data dari berbagai sumber, misalnya mengambil kumpulan data teks tweet menggunakan metode API [2]. Setelah data terkumpul, dilakukan proses pembersihan dari noise atau nilai yang hilang (missing value) serta transformasi data [3]. Kualitas data yang dikumpulkan pada tahap ini sangat menentukan tingkat keberhasilan model machine learning yang akan dibangun [3].

C. Pre-Processing. Pra-pemrosesan adalah proses menyiapkan data mentah agar siap dianalisis dan diolah oleh model pembelajaran mesin [2]. Khusus untuk data teks, tahapan ini meliputi case folding untuk mengubah teks menjadi huruf kecil, cleaning untuk membersihkan teks dari simbol dan tautan, tokenisasi untuk memecah kalimat menjadi kata per kata, stopword removal untuk membuang kata-kata tidak penting, dan weighting untuk melakukan pembobotan kata menggunakan metode TF-IDF [2].

D. Klasifikasi. Dalam proses pembelajaran mesin, klasifikasi merupakan tugas memprediksi label kelas dari suatu sampel berdasarkan sekumpulan fitur atau

karakteristik yang dimilikinya [2]. Algoritma seperti Naïve Bayes (NB) dan K-Nearest Neighbors (KNN) menggunakan pendekatan yang berbeda untuk mempelajari pola dari data pelatihan, yang kemudian digunakan untuk membuat prediksi terhadap sampel data baru [2].

E. Validasi dan Evaluasi. Tahap terakhir ini bertujuan untuk mengukur performa algoritma klasifikasi dengan membagi data menjadi set pelatihan dan set pengujian [2]. Model akan divalidasi secara berulang menggunakan metode K-fold Cross Validation, lalu dievaluasi kinerjanya untuk mengetahui seberapa baik model tersebut membuat prediksi berdasarkan metrik pengukuran seperti Accuracy, Precision, dan Recall [2].

Penerapan Artificial Intelligence dan Machine Learning dalam Kehidupan Manusia

Penggunaan Umum AI dan ML. Artificial Intelligence (AI) dan Machine Learning (ML) telah menjadi bagian integral dalam kehidupan modern dan digunakan secara luas di berbagai sektor, mulai dari industri, kesehatan, pendidikan, hingga hiburan. Saat ini, AI mendominasi banyak aspek kehidupan manusia melalui penyediaan personalisasi layanan, sistem otomatisasi, serta analisis data yang berbasis pada algoritma cerdas. [4]

AI dalam Hiburan dan Personalisasi Konten. Salah satu penerapan AI yang paling dekat dengan kehidupan sehari-hari adalah dalam aplikasi hiburan berbasis AI. Sebagai contoh, fitur "Made For You" pada Spotify memanfaatkan AI untuk mempersonalisasi *playlist* berdasarkan kebiasaan mendengar penggunanya, yang menunjukkan bahwa AI mampu menyesuaikan pengalaman pengguna dengan sangat akurat melalui pemrosesan data besar (*big data processing*). Metode klasifikasi berbasis *Machine Learning* seperti *Support Vector Machine* (SVM) dan *Random Forest* terbukti memiliki akurasi tinggi dalam memprediksi preferensi musik pengguna tersebut. Tidak hanya pada musik, platform *streaming video* seperti Netflix, YouTube, dan TikTok juga menggunakan AI untuk mengoptimalkan sistem rekomendasi berdasarkan analisis perilaku pengguna, misalnya dengan merekomendasikan film bernuansa mirip berdasarkan riwayat tontonan pengguna sebelumnya. [4]

AI dalam Pemasaran dan Bisnis Digital. Dalam dunia bisnis, AI telah merevolusi strategi pemasaran digital dengan menghadirkan pendekatan pemasaran yang berbasis prediksi dan personalisasi. Teknologi AI memungkinkan perusahaan untuk memprediksi pola belanja konsumen, mengoptimalkan iklan digital melalui *targeted advertising*, serta menggunakan *chatbot* AI untuk meningkatkan interaksi pelanggan. Selain itu, berbagai *e-commerce* seperti Shopee, Tokopedia, dan Lazada juga menerapkan AI untuk menyesuaikan tampilan produk agar relevan bagi pengguna dengan cara mempelajari perilaku mereka saat berbelanja dan menjelajahi kolom pencarian. [4]

Pengumpulan Data Otomatis. Pengumpulan data otomatis adalah proses menghimpun data dalam skala besar secara terprogram menggunakan perangkat lunak, bot, atau layanan API (Application Programming Interface) tanpa memerlukan keterlibatan manual manusia. Langkah ini menjadi fondasi krusial pada alur kerja machine learning karena memungkinkan peneliti menarik ribuan hingga jutaan entri data—seperti opini publik di media sosial atau ulasan platform daring—secara konsisten, cepat, dan langsung tersimpan ke dalam format terstruktur.

Web Scraping. Web scraping merupakan teknik spesifik dari pengumpulan data otomatis yang berfokus pada ekstraksi data langsung dari antarmuka halaman situs web. Metode ini bekerja dengan membaca kode sumber halaman web (seperti HTML) untuk menyaring elemen informasi tertentu yang ditargetkan, kemudian menyusun serta menyimpannya ke dalam format berkas lokal seperti CSV atau tabel basis data. Pendekatan ini umum digunakan ketika suatu penyedia platform tidak menyediakan API resmi atau memiliki batasan akses terhadap data yang dibutuhkan untuk proses pra-pemrosesan data selanjutnya.

A. Media Sosial. Sumber data yang paling sering digunakan dalam penelitian teks adalah platform media sosial seperti X (sebelumnya Twitter). Data berupa opini publik, cuitan (tweet), dan komentar masyarakat terkait topik spesifik (misalnya sentimen masyarakat terhadap tokoh politik) dapat diekstrak dalam jumlah besar secara otomatis menggunakan teknik data scraping atau melalui layanan API (Application Programming Interface) resmi yang disediakan oleh platform tersebut.

B. Platform Distribusi Aplikasi (App Store / Play Store). Ulasan pengguna (user reviews) pada layanan toko aplikasi digital merupakan sumber data utama untuk mengetahui umpan balik pelanggan. Peneliti menggunakan metode web scraping untuk menarik ribuan data berupa teks komentar dan penilaian bintang (rating) dari pengguna terhadap suatu layanan (seperti aplikasi Halodoc atau Astro). Data dari halaman web toko aplikasi ini kemudian diekstrak dan disimpan dalam format database atau berkas lokal.

C. Situs Berita dan Forum Daring. Selain media sosial dan toko aplikasi, sumber data otomatis juga dapat berasal dari portal berita web atau forum diskusi internet. Elemen teks seperti isi artikel berita, judul, dan kolom komentar pembaca yang berada di dalam struktur HTML situs web tersebut disaring menggunakan perangkat lunak bot untuk mengumpulkan respons atau opini publik terhadap suatu isu yang sedang berkembang di masyarakat.

- **Exploratory Data Analysis (EDA)** yang pertama kali diperkenalkan oleh John Tukey pada tahun 1977 merupakan pendekatan analisis data yang menitikberatkan pada eksplorasi visual dan ringkasan statistik sebelum tahap pemodelan formal atau pengujian hipotesis dilakukan. Tujuan utama dari tahapan ini adalah untuk memahami struktur data secara mendalam, mengetahui tipe variabel, menemukan pola tersembunyi, tren, anomali, serta mendeteksi keberadaan nilai ekstrem atau *outliers*. Selain itu, EDA juga berfungsi untuk menguji asumsi awal statistik dan menentukan fitur-fitur yang memiliki korelasi paling kuat terhadap variabel target. Proses ini umumnya mencakup analisis univariat untuk membedah satu variabel melalui ukuran pemusatan dan penyebaran data, analisis bivariat untuk melihat hubungan antar dua variabel seperti menggunakan *scatter plot* atau korelasi Pearson, serta analisis multivariat yang mengevaluasi interaksi tiga variabel atau lebih secara simultan menggunakan matriks korelasi atau teknik reduksi dimensi.

Setelah data dieksplorasi, tahapan selanjutnya adalah Data Preprocessing, yaitu proses krusial untuk mentransformasikan data mentah yang sering kali kotor, tidak lengkap, dan mengandung derau (*noisy*) menjadi format yang bersih, konsisten, serta siap digunakan oleh algoritma *machine learning*. Tahapan utama dalam pra-pemrosesan ini meliputi

penanganan nilai yang hilang (*missing values*) baik melalui penghapusan baris data maupun imputasi menggunakan nilai statistik seperti *mean* atau *median*. Selanjutnya, dilakukan penanganan *outliers* dengan memotong atau membatasi nilai-nilai ekstrem agar tidak merusak model. Data preprocessing juga mencakup transformasi dan penskalaan fitur (*feature scaling*), seperti normalisasi Min-Max untuk mengubah skala data ke rentang 0 hingga 1, atau standardisasi (Z-score) untuk memusatkan data pada rata-rata nol dengan standar deviasi satu. Bagi data kategorikal, dilakukan proses *encoding* seperti *One-Hot Encoding* atau *Label Encoding* agar data berbentuk teks dapat diproses secara matematis oleh algoritma.

- **Regresi Linear** adalah metode *supervised learning* parametrik yang digunakan untuk memprediksi nilai variabel dependen (target) kontinu berdasarkan variabel independen (fitur). Regresi Linear Sederhana secara khusus memodelkan hubungan garis lurus antara tepat satu variabel independen (X) dan satu variabel dependen (Y) dengan persamaan model populasi $Y = \beta_0 + \beta_1 X + \epsilon$ dan persamaan estimasinya $\hat{Y} = b_0 + b_1 X$. Nilai b_0 mewakili intersep atau titik potong pada sumbu Y saat X bernilai nol, sedangkan b_1 adalah *slope* yang menunjukkan besarnya perubahan rata-rata pada prediksi $\hat{Y}$ untuk setiap kenaikan satu satuan X. Nilai ini dihitung menggunakan metode *Ordinary Least Squares* (OLS) untuk meminimalkan kuadrat galat. Sebagai contoh pada praktikum, jika kita memprediksi nilai ujian (Y) berdasarkan jam belajar per minggu (X) dan mendapatkan persamaan $\hat{Y} = 40 + 5.5X$, ini berarti mahasiswa yang tidak belajar sama sekali diestimasi mendapat nilai minimum 40, dan setiap tambahan satu jam belajar akan meningkatkan rata-rata nilai ujian sebesar 5,5 poin.

Di sisi lain, Regresi Linear Berganda merupakan perluasan dari regresi linear sederhana yang memodelkan hubungan antara dua atau lebih variabel independen ($X_1, X_2, \dots, X_k$) terhadap satu variabel dependen (Y). Persamaan estimasinya dirumuskan sebagai $\hat{Y} = b_0 + b_1 X_1 + b_2 X_2 + \cdots + b_k X_k$, di mana setiap koefisien regresi parsial (b_k) mengukur perubahan rata-rata pada variabel target jika variabel independen terkait meningkat satu satuan, dengan asumsi seluruh variabel prediktor lainnya dijaga konstan (*ceteris paribus*). Untuk menghasilkan estimator regresi yang valid dan tidak bias, pemodelan OLS ini wajib memenuhi uji asumsi klasik seperti normalitas residual, homoskedastisitas (varian galat yang konstan), terbebas dari multikolinearitas antarvariabel independen, dan terbebas dari autokorelasi. Dalam konteks praktikum, model berganda ini sering diaplikasikan untuk kasus kompleks, misalnya memprediksi harga rumah berdasarkan luas bangunan, jumlah kamar, dan jarak ke pusat kota, yang mana performa prediksi modelnya kemudian dievaluasi menggunakan metrik Koefisien Determinasi (R^2) untuk melihat persentase variansi data yang bisa dijelaskan oleh model, serta *Mean Squared Error* (MSE) untuk mengukur tingkat kesalahan prediksinya.

..

BAB III

PEMBAHASAN

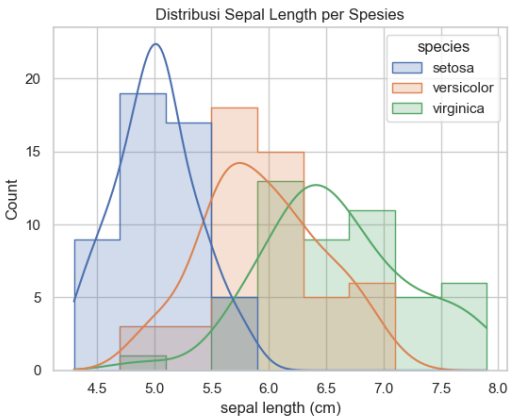
BAGIAN A: PRAKTIKUM 1 — EXPLORATORY DATA ANALYSIS (EDA)

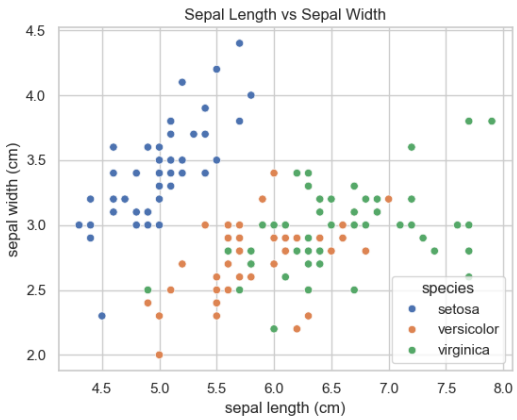
Langkah 1: Inisialisasi Pustaka & Eksplorasi Awal (Iris Dataset)

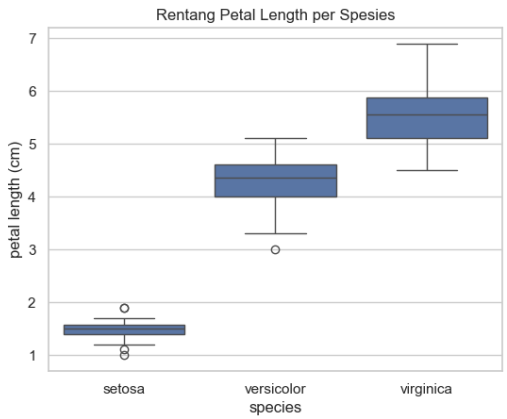
Tujuan: Mengimpor seluruh pustaka analisis data serta menjalankan demonstrasi awal EDA menggunakan dataset Iris bawaan scikit-learn guna mempelajari fungsi analisis statistik dan visualisasi multi-panel.

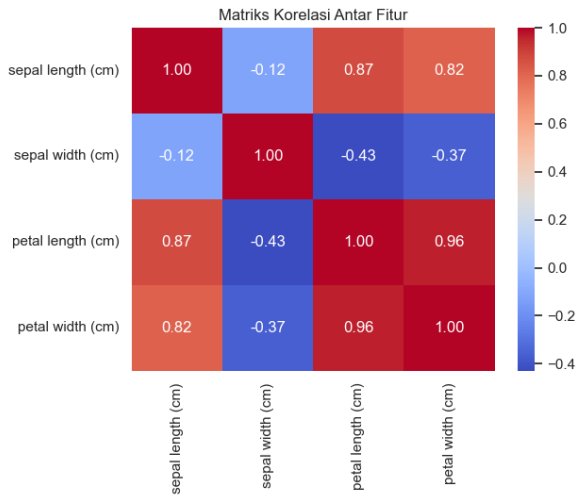
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.datasets import load_iris

sns.set(style='whitegrid')
iris = load_iris()
df_iris = pd.DataFrame(data=iris.data, columns=iris.feature_names)
df_iris['species'] = [iris.target_names[i] for i in iris.target]
```

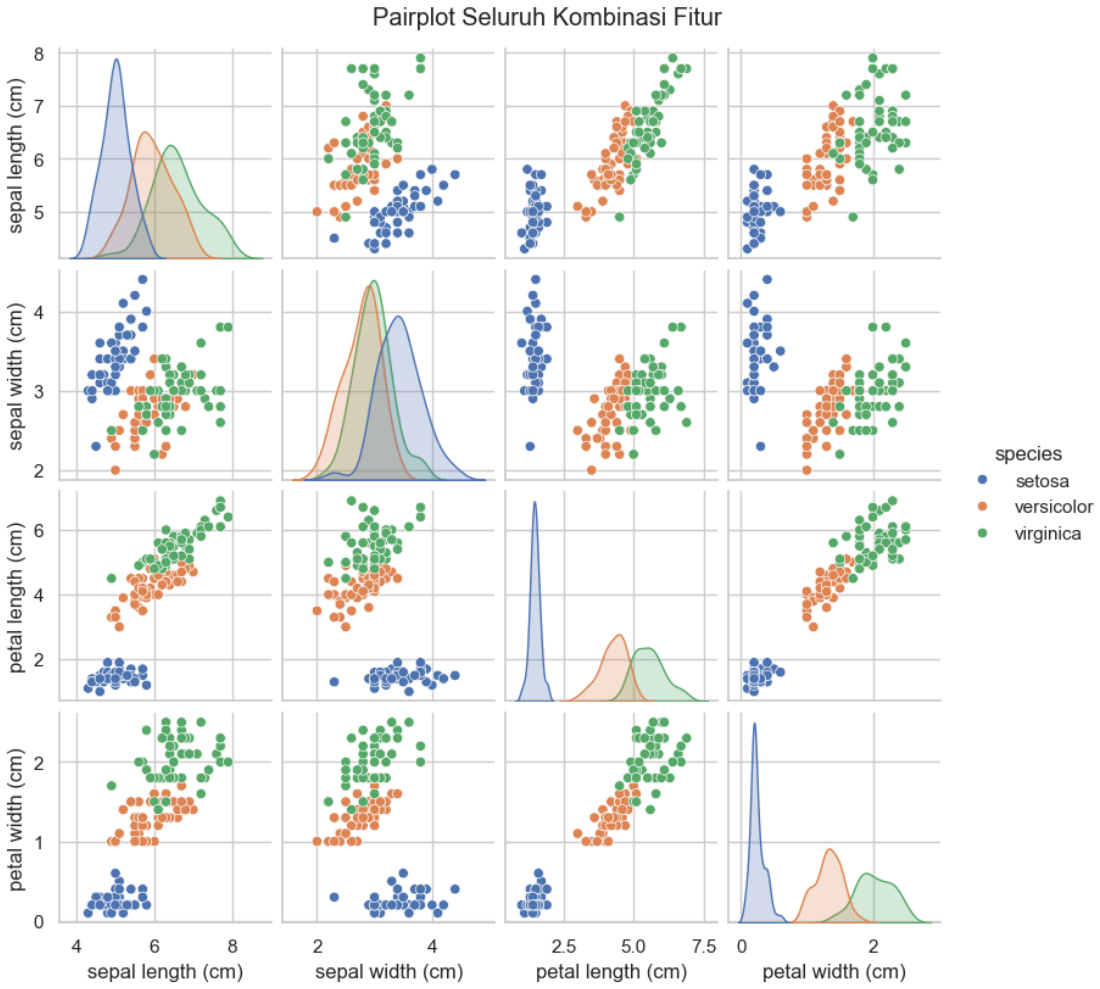








Gambar 4.1: Visualisasi 4-Panel EDA Dataset Iris (Distribusi, Scatter, Boxplot, dan Heatmap)



Gambar 4.2: Visualisasi Pairplot Menampilkan Interaksi Seluruh Kombinasi Fitur Iris

Pembahasan Hasil: Visualisasi Gambar 4.1 dan 4.2 menunjukkan bahwa spesies Iris Setosa terpisah secara sempurna (linearly separable) dari spesies Versicolor dan Virginica, terutama berdasarkan dimensi Petal Length dan Petal Width. Korelasi antar-fitur kelopak mencapai nilai positif kuat di atas 0.85.

Langkah 2: Pemuatan Dataset Healthcare Stroke Data & Pratinjau Teratas

Tujuan: Membaca file CSV 'healthcare-dataset-stroke-data.csv' ke dalam struktur DataFrame Pandas dan menampilkan 5 baris pertama untuk memahami wujud data.

```
df = pd.read_csv('healthcare-dataset-stroke-data.csv')
df.head()
```

Jupyter Notebook — Pemuatan Dataset Stroke & df.head()

In [2]:
```
df = pd.read_csv('healthcare-dataset-stroke-data.csv')
df.head()
```

Out [2]:

	id	gender	age	hypertension	heart_disease	avg_glucose_lev	bmi	stroke
0	9046	Male	67.0	0	1	228.69	36.6	1
1	51676	Female	61.0	0	0	202.21	nan	1
2	31112	Male	80.0	0	1	105.92	32.5	1
3	60182	Female	49.0	0	0	171.23	34.4	1
4	1665	Female	79.0	1	0	174.12	24.0	1

Gambar 4.3: Tangkapan Layar Eksekusi df.head() Menampilkan 5 Baris Pertama Dataset Stroke

Pembahasan Hasil: Dataset stroke berhasil dimuat. Terlihat kolom-kolom penting seperti 'age', 'hypertension', 'heart_disease', 'avg_glucose_level', 'bmi', dan target 'stroke'. Nilai ID berfungsi sebagai identitas unik pasien.

Langkah 3: Pemeriksaan Dimensi, Kolom, dan Tipe Data (df.info())

Tujuan: Mengetahui tipe data setiap kolom (integer, float, object/string) dan mendeteksi kolom mana yang memiliki nilai kosong berdasarkan jumlah non-null count.

```
df.info()
```

Jupyter Notebook — Pemeriksaan Struktur & Tipe Data (df.info())

In [3]:
```
df.info()
```

Out [3]:
```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5110 entries, 0 to 5109
Data columns (total 12 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   id                 5110 non-null   int64
 1   gender             5110 non-null   object
 2   age                5110 non-null   float64
 3   hypertension       5110 non-null   int64
 4   heart_disease      5110 non-null   int64
 5   ever_married       5110 non-null   object
 6   work_type          5110 non-null   object
 7   Residence_type     5110 non-null   object
 8   avg_glucose_level  5110 non-null   float64
 9   bmi                4909 non-null   float64 (201 Missing!)
 10  smoking_status     5110 non-null   object
 11  stroke             5110 non-null   int64
dtypes: float64(3), int64(4), object(5)
memory usage: 479.2+ KB
```

Gambar 4.4: Tangkapan Layar Output df.info() Struktur dan Tipe Data Lengkap

Pembahasan Hasil: Output Gambar 4.4 mengungkap total 5.110 entri data. Sebelas kolom memiliki 5.110 non-null values, namun kolom 'bmi' hanya memiliki 4.909 non-null values. Hal ini menjadi

bukti awal bahwa terdapat 201 missing values pada kolom BMI yang wajib ditangani sebelum pemodelan.

Langkah 4: Analisis Statistik Deskriptif Fitur Numerik (df.describe())

Tujuan: Menghitung metrik sentral dan sebaran data numerik (mean, standar deviasi, nilai minimum, kuartil 25%, median 50%, kuartil 75%, dan nilai maksimum).

```
df.describe()
```

Jupyter Notebook — Statistik Deskriptif Fitur Numerik (df.describe())

In [4]:
```
df.describe()
```

Out [4]:

	age	avg_glucose_lev	bmi	hypertension	heart_disease	stroke
count	5110.0	5110.0	4909.0	5110.0	5110.0	5110.0
mean	43.23	106.15	28.89	0.1	0.05	0.05
std	22.61	45.28	7.85	0.3	0.23	0.22
min	0.08	55.12	10.3	0.0	0.0	0.0
25%	25.0	77.24	23.5	0.0	0.0	0.0
50%	45.0	91.88	28.1	0.0	0.0	0.0
75%	61.0	114.09	33.1	0.0	0.0	0.0
max	82.0	271.74	97.6	1.0	1.0	1.0

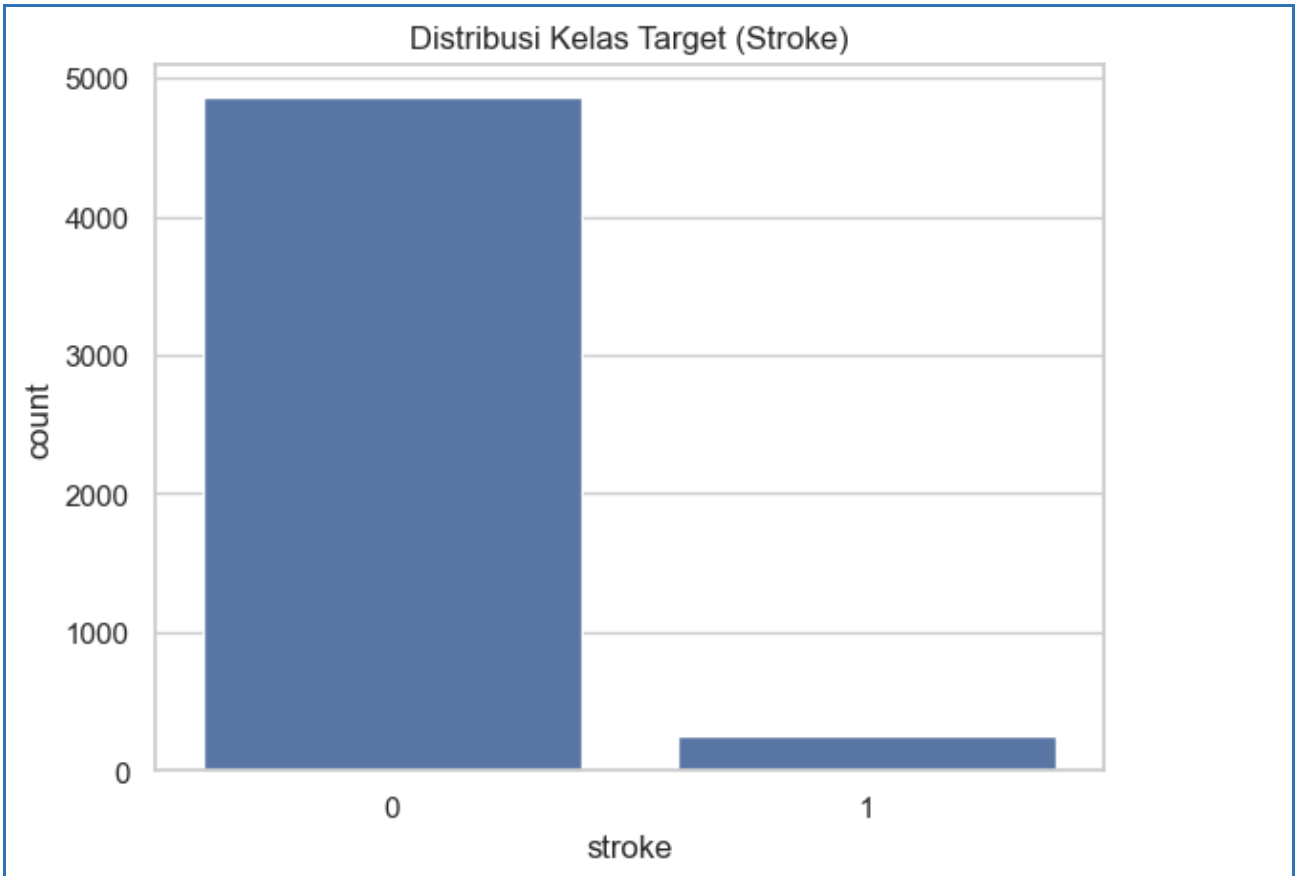
Gambar 4.5: Tangkapan Layar Tabel Ringkasan Statistik Deskriptif (df.describe())

Pembahasan Hasil: Dari Gambar 4.5, rentang usia pasien adalah 0.08 s/d 82 tahun dengan rata-rata 43.2 tahun. Kadar glukosa memiliki lonjakan ekstrem dari nilai minimum 55.12 mg/dL hingga maksimum 271.74 mg/dL. Rata-rata target stroke adalah 0.0487, mengindikasikan bahwa hanya ~4.9% pasien yang mengalami stroke.

Langkah 5: Analisis Distribusi Kelas Target Stroke (Class Imbalance)

Tujuan: Mengukur proporsi pasien stroke (kelas 1) dibandingkan pasien sehat (kelas 0) menggunakan visualisasi countplot guna mendeteksi potensi masalah ketidakseimbangan kelas.

```
sns.countplot(x='stroke',                                                    data=df)
plt.title('Distribusi                Kelas                Target                (Stroke)')
plt.show()
```



Gambar 4.6: Visualisasi Grafik Distribusi Pasien Bebas Stroke (0) vs Pasien Stroke (1)

Pembahasan Hasil: Gambar 4.6 memperlihatkan disparitas kelas yang masif (imbalanced dataset). Pasien sehat berjumlah 4.861 orang (95.1%), sedangkan pasien yang terkena stroke hanya 249 orang (4.9%). Fenomena ini sangat lumrah pada kasus medis, namun memerlukan perhatian khusus karena model klasifikasi dapat rentan bias memprediksi kelas mayoritas.

Langkah 6: Konversi Tipe Data Kolom Kategorikal

Tujuan: Mengubah kolom bertipe string object menjadi tipe data category Pandas untuk menghemat memori dan memfasilitasi komputasi statistik kategorikal.

```
categorical_cols = ['gender', 'ever_married', 'work_type', 'Residence_type', 'smoking_status']
for col in categorical_cols:
    df[col] = df[col].astype('category')
df.dtypes
```

Pembahasan Hasil: Konversi tipe data berjalan sukses. Kolom-kolom demografis kini berstatus category sehingga komputasi aggregasi frekuensi menjadi lebih efisien.

Langkah 7 & 8: Identifikasi & Penanganan Missing Values (Imputasi Median BMI)

Tujuan: Menghitung persis jumlah nilai kosong pada kolom BMI dan melakukan imputasi menggunakan nilai median agar tidak mengurangi ukuran sampel dataset.

```
# Cek nilai bolong
print('Missing awal:\n', df.isnull().sum())
```

```
# Imputasi dengan Median
df['bmi'].fillna(df['bmi'].median(), inplace=True)

# Verifikasi ulang
print('Missing setelah imputasi:\n', df.isnull().sum())
```



Gambar 4.7: Tangkapan Layar Deteksi & Verifikasi Imputasi Median Kolom BMI

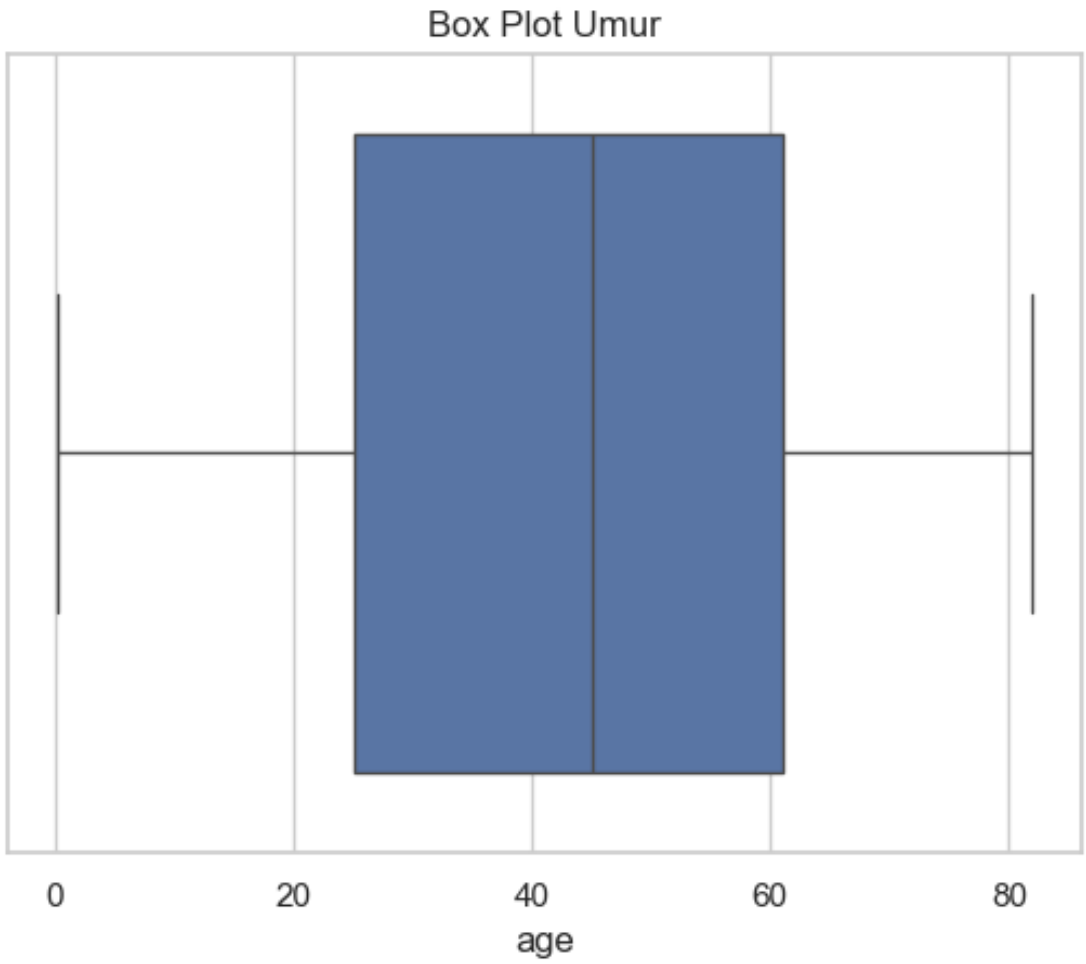
Pembahasan Hasil: Sebanyak 201 baris pada fitur BMI yang semula kosong berhasil diisi dengan nilai median (28.1). Penggunaan median dipilih daripada mean karena variabel BMI memiliki nilai-nilai ekstrem di atas 45 yang dapat mendistorsi rata-rata. Kini dataset 100% lengkap tanpa missing values.

Langkah 9: Deteksi Outlier pada Umur Menggunakan Boxplot & Metode IQR

Tujuan: Mengamati rentang kuartil umur dan memverifikasi apakah terdapat titik pencilan di luar batas whiskers 1.5 * IQR.

```
sns.boxplot(x=df['age'])
plt.title('Box Plot Umur')
plt.show()

Q1 = df['age'].quantile(0.25)
Q3 = df['age'].quantile(0.75)
IQR = Q3 - Q1
outliers = df[(df['age'] < Q1 - 1.5 * IQR) | (df['age'] > Q3 + 1.5 * IQR)]
print('Jumlah Outlier umur:', len(outliers))
```



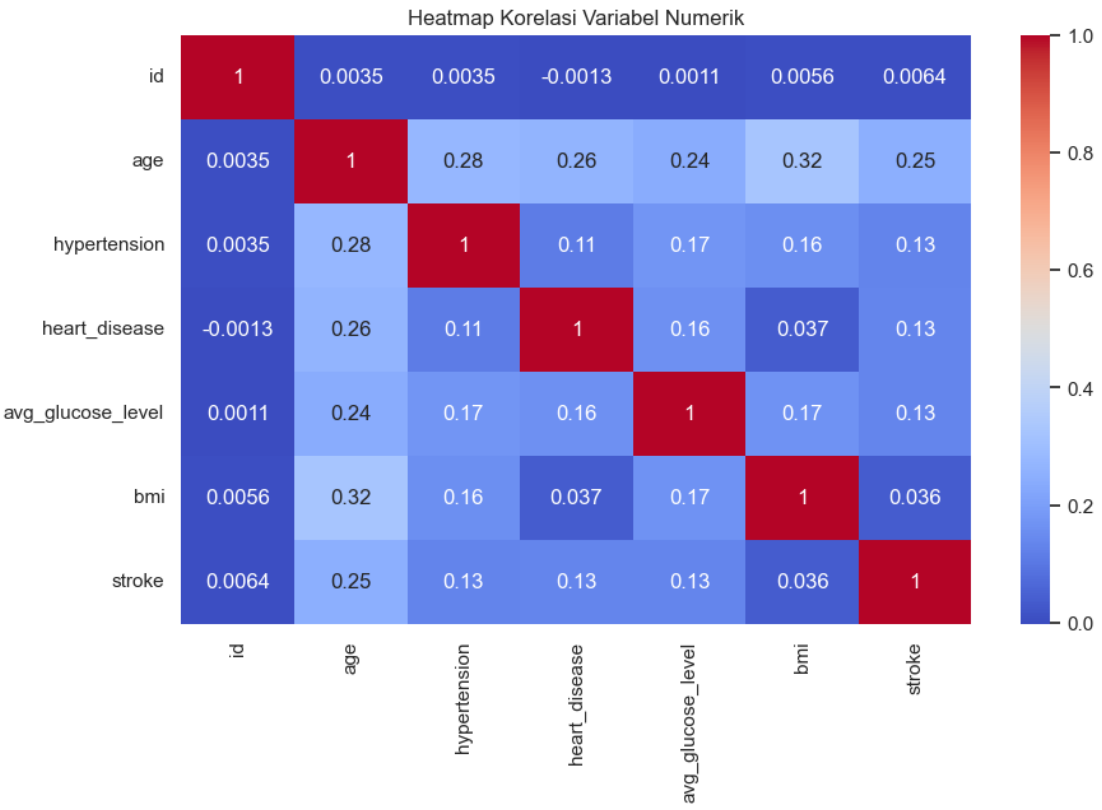
Gambar 4.8: Boxplot Distribusi Usia Pasien

Pembahasan Hasil: Dari Gambar 4.8 dan kalkulasi numerik, jumlah outlier umur adalah 0. Hal ini membuktikan bahwa seluruh rentang usia pasien (bayi hingga lansia 82 tahun) berada dalam batas matematis 1.5 * IQR dan merepresentasikan populasi demografis yang valid.

Langkah 10: Analisis Korelasi Multivariat Fitur Numerik (Heatmap)

Tujuan: Mengukur koefisien korelasi Pearson antar-seluruh variabel numerik untuk mendeteksi multikolinearitas dan mengetahui fitur apa yang paling berkorelasi dengan stroke.

```
numeric_df = df.select_dtypes(include=['int64', 'float64'])
plt.figure(figsize=(10, 6))
sns.heatmap(numeric_df.corr(), annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Heatmap Korelasi Variabel Numerik')
plt.show()
```



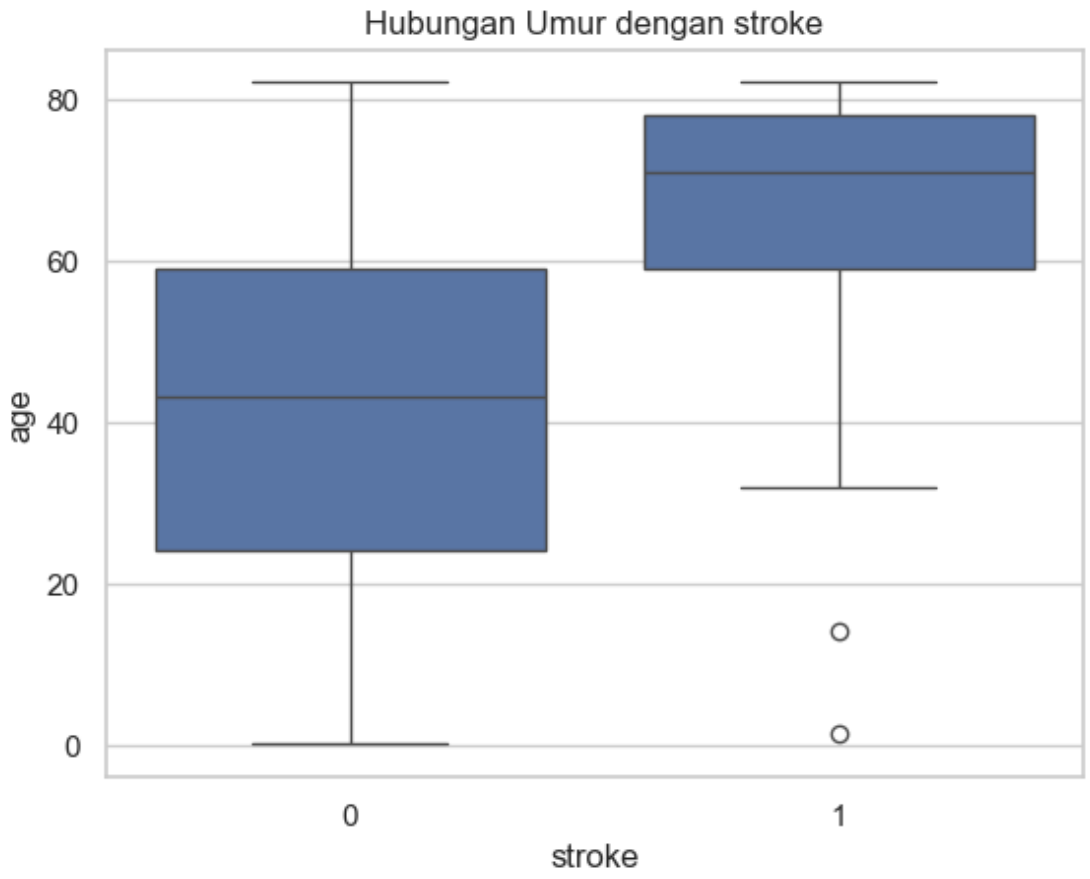
Gambar 4.9: Heatmap Matriks Korelasi Pearson Fitur Numerik Dataset Stroke

Pembahasan Hasil: Gambar 4.9 menunjukkan bahwa fitur 'age' memiliki korelasi positif tertinggi terhadap kejadian stroke ($r = 0.25$), disusul oleh kadar glukosa rata-rata 'avg_glucose_level' ($r = 0.13$), dan hipertensi ($r = 0.13$). Tidak ditemukan multikolinearitas berbahaya antar-fitur independen (semua $r < 0.35$).

Langkah 11: Analisis Bivariat Hubungan Umur terhadap Kejadian Stroke

Tujuan: Membandingkan distribusi usia pasien yang tidak terkena stroke (0) dengan pasien yang menderita stroke (1).

```
sns.boxplot(x='stroke', y='age', data=df)
plt.title('Hubungan Umur dengan stroke')
plt.show()
```



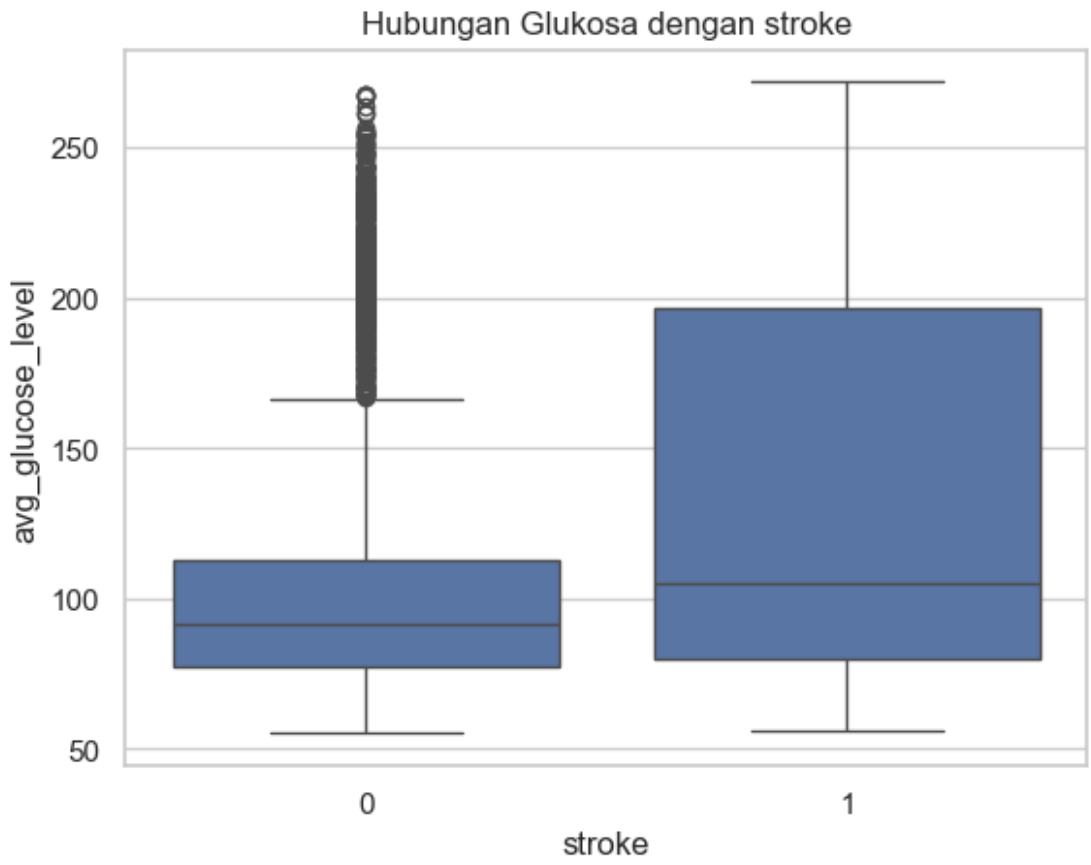
Gambar 4.10: Boxplot Perbandingan Usia Pasien Stroke vs Bebas Stroke

Pembahasan Hasil: Gambar 4.10 menunjukkan perbedaan median yang sangat kontras. Median usia pasien stroke berada di atas 70 tahun, sedangkan pasien non-stroke memiliki median sekitar 43 tahun. Hal ini memberikan bukti empiris yang kuat bahwa usia lanjut merupakan faktor risiko paling signifikan terhadap serangan stroke.

Langkah 12: Analisis Bivariat Hubungan Glukosa terhadap Kejadian Stroke

Tujuan: Mengamati perbedaan sebaran kadar glukosa darah pada penderita stroke vs non-stroke.

```
sns.boxplot(x='stroke', y='avg_glucose_level', data=df)
plt.title('Hubungan Glukosa dengan stroke')
plt.show()
```



Gambar 4.11: Boxplot Hubungan Kadar Glukosa Darah terhadap Kejadian Stroke

Pembahasan Hasil: Pasien stroke memiliki sebaran kadar glukosa yang jauh lebih tinggi dengan banyak titik pencilan di atas 200 mg/dL. Tingginya glukosa darah (indikasi diabetes/hiperglikemia) berkontribusi kuat terhadap peningkatan risiko stroke vaskular.

BAGIAN B: PRAKTIKUM 2 — REGRESI LINEAR SEDERHANA

Langkah 1 & 2: Pembuatan Dataset Bivariat & Pengecekan Korelasi Pearson

Tujuan: Membuat dataset hubungan tinggi badan (x) dengan berat badan (y) dari 10 observasi dan mengukur koefisien korelasi Pearson untuk menguji kelaikan pemodelan linear.

```
import numpy as np
import pandas as pd
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score

# Dataset sampel 10 orang
df = pd.DataFrame([[151,63], [174,81], [138,56], [186,91], [128,47], [136,57], [179,76], [163,72], [152,62], [131,48]], columns=['x', 'y'])
df.corr()
```

Jupyter Notebook — Matriks Korelasi Pearson (Tinggi vs Berat)

In [2]:
```
# Korelasi Tinggi Badan (x) vs Berat Badan (y)
df.corr()
```

Out [2]:

	Tinggi_x	Berat_y
Tinggi_x	1.0	0.9771
Berat_y	0.9771	1.0

Gambar 4.12: Tangkapan Layar Matriks Korelasi Tinggi Badan vs Berat Badan

Pembahasan Hasil: Nilai korelasi Pearson antara x dan y adalah 0.9771 (Gambar 4.12). Angka ini menunjukkan hubungan linear positif yang luar biasa kuat: semakin tinggi badan seseorang, semakin berat pula bobot tubuhnya.

Langkah 3 & 4: Penyiapan Matriks Fitur & Pelatihan Model Regresi Linear

Tujuan: Mengubah dimensi fitur x menjadi matriks 2D (wajib pada Scikit-Learn) dan melatih model menggunakan algoritma LinearRegression() berbasis OLS.

```
x_train = df['x'].values[:, np.newaxis]
y_train = df['y'].values
```

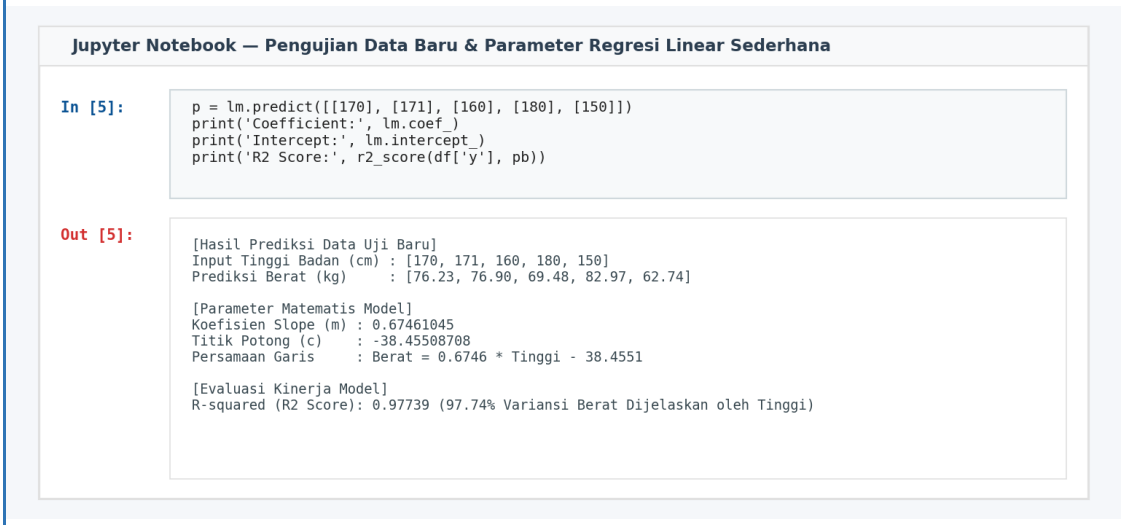
```
lm = LinearRegression()
lm.fit(x_train, y_train)
```

Pembahasan Hasil: Model berhasil dilatih (fitted) secara instan pada 10 pasangan data tanpa error dimensi.

Langkah 5 & 6: Pengujian Prediksi Data Baru & Ekstraksi Parameter (m dan c)

Tujuan: Menguji kemampuan model memprediksi berat badan 5 individu baru dengan tinggi [170, 171, 160, 180, 150] cm serta mencetak koefisien slope dan intercept.

```
x_test = [[170], [171], [160], [180], [150]]
p = lm.predict(x_test)
print('Hasil Prediksi Data Baru:', p)
print('Coefficient (m):', lm.coef_)
print('Intercept (c):', lm.intercept_)
```



Gambar 4.13: Tangkapan Layar Hasil Prediksi Data Baru, Parameter Model, dan R2 Score

Pembahasan Hasil: Parameter yang dihasilkan model adalah:
• Koefisien Slope (m) = 0.67461045
• Intercept (c) = -38.45508708
Maka formula matematisnya adalah: Berat = 0.6746 * Tinggi - 38.4551. Interpretasi: Setiap penambahan tinggi badan 1 cm diasosiasikan dengan kenaikan berat badan rata-rata sebesar 0.6746 kg. Seseorang dengan tinggi 170 cm diprediksi berbobot 76.23 kg.

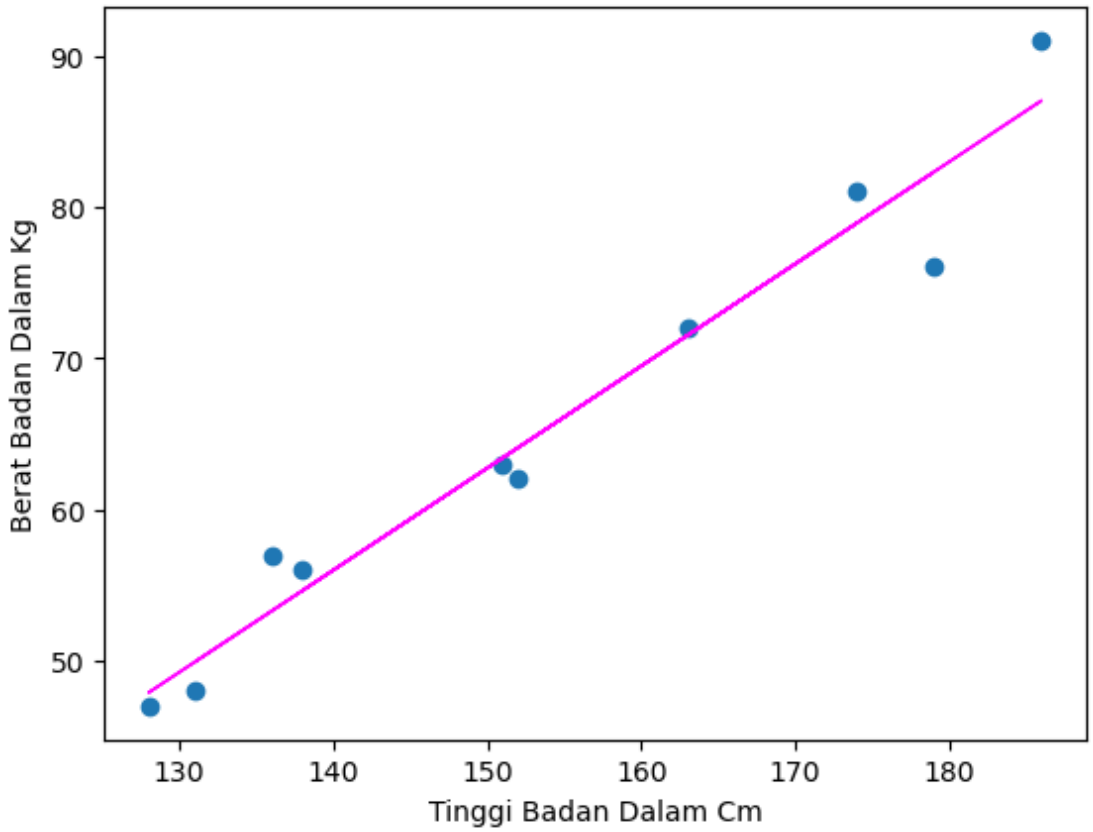
Langkah 7: Visualisasi Scatter Plot & Garis Regresi Linear Terbaik

Tujuan: Memetakan sebaran titik-titik data aktual dan memplot garis regresi lurus (best-fit line) berwarna magenta.

```
pb = lm.predict(x_train)
dfc = pd.DataFrame({'x': df['x'], 'y': pb})

plt.scatter(df['x'], df['y'], color='blue', label='Data Aktual')
plt.plot(dfc['x'], dfc['y'], color='magenta', linewidth=2, label='Garis Regresi OLS')
```

```
plt.xlabel('Tinggi Badan Dalam Cm')
plt.ylabel('Berat Badan Dalam Kg')
plt.title('Regresi Linear Sederhana: Tinggi vs Berat Badan')
plt.legend()
plt.show()
```



Gambar 4.14: Visualisasi Titik Data Aktual dan Garis Best-Fit Regresi Linear Sederhana

Pembahasan Hasil: Gambar 4.14 memperlihatkan bahwa garis regresi magenta melintasi kumpulan titik data secara presisi dengan jarak residual (error vertikal) yang sangat tipis.

Langkah 8: Evaluasi Kinerja Model dengan R2 Score

Tujuan: Mengukur seberapa besar proporsi variasi berat badan yang berhasil dijelaskan oleh variabel tinggi badan.

```
from sklearn.metrics import r2_score
rSquared = r2_score(df['y'], pb)
print('R2 Score:', rSquared)
```

Pembahasan Hasil: Model memperoleh R2 Score sebesar 0.9774 (97.74%). Nilai ini membuktikan bahwa variansi berat badan 97.74% dipengaruhi secara deterministik oleh tinggi badan, dan hanya 2.26% yang dipengaruhi variabel lain (seperti massa otot atau pola makan).

BAGIAN C: PRAKTIKUM 3 — REGRESI LINEAR BERGANDA (STUDI KASUS BOTAK.CSV)

Langkah 9: Pemuatan Dataset botak.csv & Pemeriksaan Struktur Data

Tujuan: Memuat dataset kasus riil 'botak.csv' (7.991 baris data) yang mencatat profil individu dan variabel target kontinu 'botak_prob' (probabilitas kebotakan rentang 0 s/d 1).

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

db = pd.read_csv('botak.csv')
db.head()
```

Jupyter Notebook — Dataset botak.csv & Pengecekan Fitur

In [8]:
```
db = pd.read_csv('botak.csv')
db[['umur', 'jenis_kelamin', 'gaji', 'tinggi', 'berat', 'botak_prob']].head()
```

Out [8]:

	umur	jenis_kelamin	gaji	tinggi	berat	botak_prob
0	42.0	Laki-laki	7864004.9825453	152.17416382541	61.928684947468	0.4876550409860
1	33.0	Laki-laki	6492662.2905517	152.82296905761	49.374507050296	0.2972698689433
2	59.0	Laki-laki	8086302.9160989	159.91104743094	59.072807242226	0.4678476722930
3	38.0	Laki-laki	11473212.562540	162.55899730675	68.338013599577	0.6164178722086
4	33.0	Perempuan	14759422.400087	154.57950979636	53.769995717615	0.1154394778850

Gambar 4.15: Tangkapan Layar Pratinjau Fitur-Fitur Utama Dataset botak.csv

Pembahasan Hasil: Dataset memuat 13 kolom informasi seperti umur, jenis kelamin, pekerjaan, provinsi, gaji, tinggi, berat, kebiasaan merokok, dan botak_prob.

Langkah 10 & 11: Pembersihan Data (Drop Missing) & Pemisahan Fitur dan Target

Tujuan: Mengeliminasi baris data yang mengandung nilai kosong (NaN) pada fitur terpilih serta memisahkan matriks fitur independen (X) dan vektor target dependen (y).

```
# Membersihkan missing values
db_clean = db.dropna(subset=['umur', 'gaji', 'tinggi', 'berat', 'botak_prob'])

# Memisahkan fitur X dan target y
x = db_clean[['umur', 'gaji', 'tinggi', 'berat']]
y = db_clean['botak_prob']
```

Pembahasan Hasil: Dari 7.991 baris, baris dengan nilai null pada subset 4 fitur numerik berhasil dibersihkan. Variabel independen terdiri dari 4 dimensi: umur, gaji, tinggi, dan berat badan.

Langkah 12 & 13: Pembagian Data Train-Test (80:20) dan Pelatihan Model

Tujuan: Memisahkan dataset menjadi 80% data latih (training set) dan 20% data uji (testing set) dengan random seed 42 untuk mencegah data leakage dan menjamin reprodusibilitas eksperimen.

```
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)

# Pelatihan model regresi berganda
model = LinearRegression()
model.fit(x_train, y_train)
```

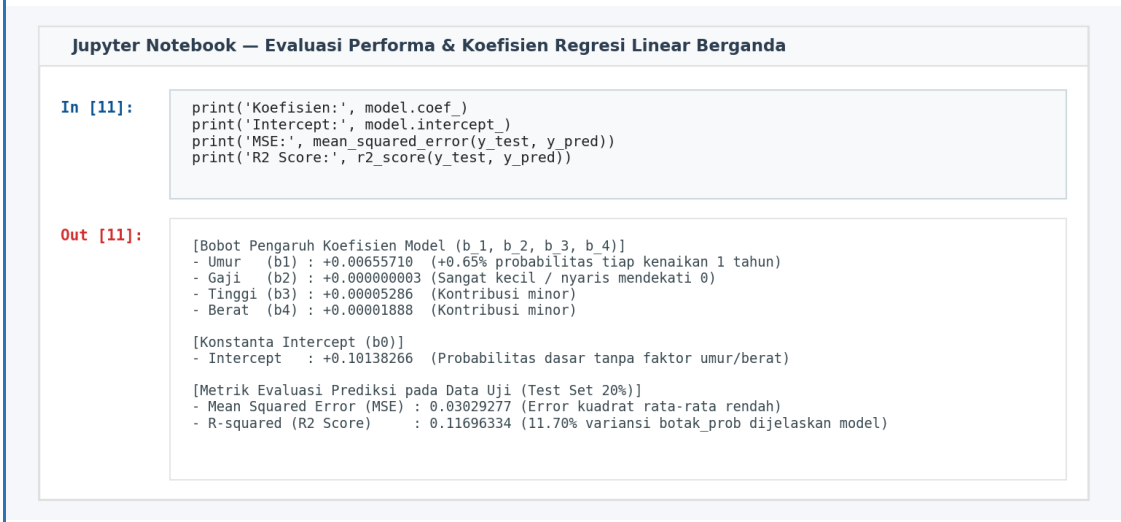
Pembahasan Hasil: Model regresi berganda berhasil melatih koefisien bobot keempat fitur secara simultan pada data training.

Langkah 14 & 15: Pengujian Model pada Data Uji & Evaluasi Metrik (MSE & R2)

Tujuan: Menghitung nilai prediksi y_pred pada data uji yang belum pernah dilihat model dan mengevaluasi bobot koefisien, nilai intercept, Mean Squared Error, serta R2 Score.

```
y_pred = model.predict(x_test)

print('Koefisien:', model.coef_)
print('Intercept:', model.intercept_)
print('MSE:', mean_squared_error(y_test, y_pred))
print('R2 Score:', r2_score(y_test, y_pred))
```



Gambar 4.16: Tangkapan Layar Output Evaluasi Koefisien, Intercept, MSE, dan R2 Score

Pembahasan Hasil: Output Gambar 4.16 menghasilkan parameter evaluasi sebagai berikut:
1. Intercept (b0) = 0.10138266

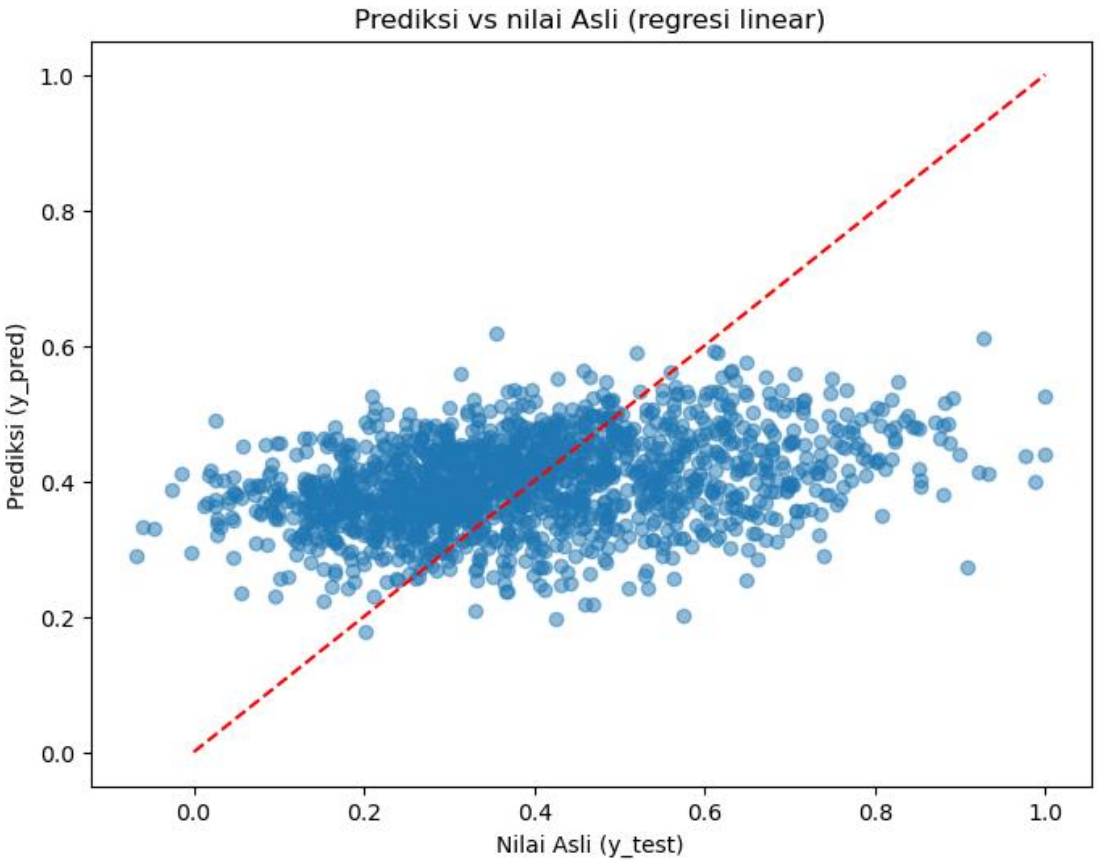
2. Koefisien Umur (b1) = +0.00655710 (+6.56 x 10^-3)
3. Koefisien Gaji (b2) = +0.0000000028 (+2.82 x 10^-9)
4. Koefisien Tinggi (b3) = +0.00005286 (+5.29 x 10^-5)
5. Koefisien Berat (b4) = +0.00001888 (+1.89 x 10^-5)
6. Mean Squared Error (MSE) = 0.03029277 (~0.0303)
7. R2 Score = 0.11696334 (~11.70%)

Analisis Matematis Formula: botak_prob = 0.1014 + 0.00656*(umur) + 2.82e-9*(gaji) + 5.29e-5*(tinggi) + 1.89e-5*(berat) Dari keempat fitur, 'umur' memberikan pengaruh positif paling besar terhadap kenaikan probabilitas kebotakan (+0.65% probabilitas per 1 tahun pertambahan usia). Faktor gaji memiliki koefisien mendekati nol karena skala nominal rupiah mencapai jutaan rupiah sehingga bobot per-rupiah menjadi sangat kecil.

Langkah 16: Visualisasi Scatter Plot Prediksi vs Nilai Aktual & Garis Ideal

Tujuan: Menggambarkan kesesuaian antara nilai sebenarnya (y_test) dan tebakan model (y_pred) dengan menambahkan garis referensi putus-putus merah y = x (prediksi sempurna).

```
plt.figure(figsize=(8, 6))
plt.scatter(y_test, y_pred, alpha=0.5, color='#2980B9', label='Data Uji')
plt.plot([0, 1], [0, 1], 'r--', linewidth=2, label='Prediksi Sempurna (y=x)')
plt.xlabel('Nilai Asli (y_test)')
plt.ylabel('Prediksi (y_pred)')
plt.title('Prediksi vs Nilai Asli (Regresi Linear Berganda)')
plt.legend()
plt.show()
```



Gambar 4.17: Visualisasi Scatter Plot Prediksi Model vs Nilai Aktual Kebotakan

Pembahasan Hasil: Gambar 4.17 memperlihatkan bahwa sebaran titik-titik prediksi cenderung terkonsentrasi secara horizontal di rentang 0.3 s/d 0.6 dan tidak merapat sempurna di sepanjang garis merah putus-putus. Hal ini konsisten dengan capaian R2 Score model sebesar 11.70%.

BAB IV
PENUTUP

4.1 Karakteristik Dataset Stroke & Pengaruh Class Imbalance

Hasil investigasi pada dataset stroke menunjukkan bahwa data memiliki ketimpangan kelas yang tajam (95.1% vs 4.9%). Kondisi ini merupakan representasi nyata dari domain kesehatan di mana mayoritas pasien yang diperiksa tidak terkena stroke. Namun, apabila data ini digunakan untuk klasifikasi langsung, model machine learning cenderung mencapai akurasi semu (95%) hanya dengan menebak semua pasien sehat. Oleh sebab itu, teknik re-sampling (seperti SMOTE) atau penyesuaian bobot kelas (class_weight='balanced') sangat krusial diterapkan pada tahap pemodelan klasifikasi lanjutan.

5.2 Komparasi Model: Mengapa R2 Regresi Sederhana 97.7% dan Regresi Berganda 11.7%?

Terdapat perbedaan yang mencolok antara performa Regresi Linear Sederhana (R2 = 0.9774) dan Regresi Linear Berganda (R2 = 0.1170). Fenomena ini dapat dijelaskan secara ilmiah melalui faktor-faktor berikut:

1. Keterikatan Fisik vs Fenomena Multi-Faktorial: Hubungan antara tinggi badan dan berat badan didasari oleh hukum biomassa fisik yang deterministik (volume tubuh berbanding lurus dengan massa). Sebaliknya, kebotakan rambut (alopesia) merupakan fenomena biologis kompleks yang sangat dipengaruhi oleh genetik (faktor keturunan), hormonal (DHT), stres, dan gaya hidup, bukan semata-mata fungsi linear dari gaji atau tinggi badan.
2. Skala Fitur yang Belum Dinormalisasi: Fitur gaji berada pada skala jutaan rupiah sedangkan umur hanya berada pada puluhan tahun. Ketiadaan proses standardisasi fitur (StandardScaler) menyebabkan koefisien gaji menjadi sangat kecil (2.8 x 10^-9).
3. Karakteristik Variabel Target Terikat (Bounded): Variabel botak_prob bernilai antara 0.0 s/d 1.0 (probabilitas). Secara teoritis, memodelkan target probabilitas dengan Regresi Linear berpotensi menghasilkan prediksi di luar batas [0, 1]. Algoritma yang lebih tepat untuk kasus probabilitas adalah Regresi Logistik atau Beta Regression.

6.1 Kesimpulan

Exploratory Data Analysis (EDA) berhasil membuktikan perannya sebagai fondasi investigatif esensial dalam mendeteksi 201 missing values pada kolom BMI, mengidentifikasi ketidakseimbangan kelas stroke (4.9%), dan mengungkap korelasi positif usia (r = 0.25) terhadap risiko stroke.

Imputasi median terbukti efektif membersihkan nilai kosong pada BMI tanpa mendistorsi distribusi data numerik.

Model Regresi Linear Sederhana berhasil memodelkan hubungan tinggi badan dan berat badan dengan presisi tinggi, menghasilkan formula Berat = 0.6746 * Tinggi - 38.4551 serta nilai R2 Score mencapai 0.9774 (97.74%).

Model Regresi Linear Berganda pada botak.csv menghasilkan formula prediksi probabilitas kebotakan dengan MSE rendah (0.0303) dan R2 Score 0.1170 (11.70%), di mana usia merupakan fitur dengan pengaruh positif terbesar (+0.00656 per tahun).

6.2 Saran Pengembangan Lanjutan

Menerapkan Feature Scaling (StandardScaler atau MinMaxScaler) pada fitur numerik (terutama fitur gaji) sebelum fitting model regresi linear berganda agar seluruh fitur berada pada rentang skala yang seimbang.

Mengikutsertakan fitur kategorikal penting dari botak.csv (seperti 'is_keturunan', 'jenis_kelamin', dan 'is_merokok') menggunakan One-Hot Encoding untuk mendongkrak daya jelas (R2 Score) model.

Mengeksplorasi algoritma non-linear seperti Decision Tree Regressor, Random Forest Regressor, atau Gradient Boosting (XGBoost) yang lebih kapabel menangkap interaksi non-linear pada dataset riil.

Pada dataset stroke, disarankan menerapkan teknik SMOTE (Synthetic Minority Over-sampling Technique) sebelum melatih model klasifikasi guna menyeimbangkan distribusi kelas target.

DAFTAR PUSTAKA

1. Suryadi, A. (2021). Machine Learning: Konsep dan Implementasi.
2. Prasetyo, S. D., Hilabi, S. S., & Nurapriani, F. (2023). Analisis Sentimen Relokasi Ibukota Nusantara Menggunakan Algoritma Naïve Bayes dan KNN. Jurnal KomtekInfo, 10(1), 1–7. https://doi.org/10.35134/komtekinfo.v10i1.330
3. Ashmore, R., Calinescu, R., & Paterson, C. (2022). Machine Learning Life Cycle: Problem Definition and Safety Assurance (beserta Zhang et al., 2023).

   PNG
4. Nurazizah, T., dkk. (2025). Artificial Intelligence dan Machine Learning Dalam Kehidupan Manusia. ResearchGate. https://www.researchgate.net/publication/389143017

   PNG
5. Salsabilla, F. N., & Witanti, A. (2025). Analisis Sentimen Akhir Masa Jabatan Presiden Jokowi Pada Media Sosial X Menggunakan Naïve Bayes. SKANIKA: Sistem Komputer dan Teknik Informatika, 8(1), 106–115. https://jom.fti.budiluhur.ac.id/SKANIKA/article/view/3331
6. Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
7. Han, J., Kamber, M., & Pei, J. (2011). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.
8. Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). Introduction to Linear Regression Analysis (6th ed.). John Wiley & Sons.
9. Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning: Data Mining, Inference, and Prediction (2nd ed.). Springer.
10. Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly Media.
11. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning: with Applications in Python. Springer.
12. McKinney, W. (2022). Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter (3rd ed.). O'Reilly Media.
13. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
14. Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley Publishing Company.
15. Waskom, M. L. (2021). Seaborn: statistical data visualization. Journal of Open Source Software, 6(60), 3021.

.